

library- bootstrap

建库档位内部机理说明书

L0-L9 十档架构 · 内部机理 · 论文出处 · 验收判据

适用对象：建库体系使用者、评审者与维护者

覆盖范围：L0-L9 十档 · 28 项论文与资料题录 · 58 断言测试体系

文档性质：v2.1 统合修订版 · 严肃模式 · 全文可溯源（W-016 降级声明见 11.6）

编写时间：2026 年 9 月

目 录

- 第 1 章 总览：双库体系与十档架构1
 - 1.1 十档架构总表 1
 - 1.2 一个贯穿全文的关键问题：机制还是表演 2
 - 1.3 阅读指南 3
- 第 2 章 L0 裸奔版：骨架与铁律的机理3
 - 2.1 目录骨架：三库分离与数据流单向 3
 - 2.2 六条铁律的工程学依据 4
 - 2.3 零依赖设计 4
- 第 3 章 L1 基础闭环版：索引与闭环的机理5
 - 3.1 会话入口与常驻预算 5
 - 3.2 task-start：任务启动的三因子检索 5
 - 3.3 wrap-up：五步收尾闭环 5
 - 3.4 互链校验 5
- 第 4 章 L2 标准校验版：体检与检索的机理6
 - 4.1 lint 体检：检查矩阵 6
 - 4.2 扩散激活检索：打分公式 7
 - 4.3 体检与检索的配合 7
- 第 5 章 L3 演化版：记忆演化的机理8
 - 5.1 schema v3：六字段的语义与出处 8
 - 5.2 演化回扫：wrap-up 第六步 8
 - 5.3 编号治理规则（v2.1 新增） 8
- 第 6 章 L4 灵魂版：身份层与用户模型的机理9

6.1 理论出处与工程形态	9
6.2 中性化纪律：一个真实事故	9
6.3 与情绪向量的关系	9
第 7 章 L5 反思版：反思合成与睡眠整理的机理	10
7.1 reflect：五步合成.....	10
7.2 睡眠整理：空闲期预计算	10
7.3 反思与演化、锦标赛的关系	10
第 8 章 L6 前沿全家桶：雷达参考的机理	10
8.1 七派分类学	11
8.2 触发器设计	11
8.3 调研方法学	11
第 9 章 L7 实验版：三个实验模块的机理	12
9.1 梦境融合（dream-fusion）	12
9.2 自动批评家（auto-critic）	12
9.3 向量检索兜底（vector-search）	12
第 10 章 L8 超绝激进档：自指演化的机理	13
10.1 宪章五条	13
10.2 全息轨迹：哈希链信任锚	14
10.2.1 威胁模型与外部锚定（v2.1 新增）	14
10.3 变异引擎：机器变异的作业流程	14
10.4 知识锦标赛：达尔文选择压	15
10.5 心智议会：多席位辩论	15
10.6 用户数字孪生与反事实沙盘	15
第 11 章 L9 内省仿生档：BCA 架构的机理.....	16
11.1 情绪式调制器（EmotionState）	16
11.2 目标栈	18

11.3 双速率记忆	18
11.4 GWT 广播总线	18
11.5 睡眠固化管线与闸门	18
11.6 DMN 空闲思考与验收三件.....	19
第 12 章 工程保障：可复现性、测试与版本化	20
12.1 可复现性三件套	20
12.2 测试体系：38 断言	20
12.3 偏差事故案例：三处偏差与 v2.0.2	21
12.4 发布四轨	21
12.5 检索评测闭环（v2.1 新增，W-022）	21
第 13 章 局限与边界	21
附录 A 论文与资料题录	22
附录 B 调研方法与可信度说明	27

说明：本目录由域代码自动生成。若编辑文档后页码发生变化，请在目录上点击右键并选择「更新域」以刷新页码。

第 1 章 总览：双库体系与十档架构

本说明书面向 library-bootstrap 建库体系的使用者、评审者与后续维护者，严肃地说明 L0 至 L9 共十个建库档位的内部机理：每一档装了什么、为什么这样设计、每个机制如何在文件与脚本层面真实运转、其理论依据来自哪篇论文或哪项工程实践，以及如何验收它不是表演。正文遵循措辞纪律：机制描述使用事实性表述，小样本运行记录一律标注样本量（不构成统计证据）；档位命名沿袭社区习惯用语（如超绝激进档），不构成能力承诺。凡引用论文均给出 arXiv 编号并汇总于附录 A。

library-bootstrap 是一个可拷贝到任意 agent harness（ZCode、Claude Code、Cursor、Codex CLI 等）的建库技能包。它把「双库自进化体系」的知识管理方法论固化为一键安装流程：knowledge 库回答「怎么做事」（教训、范式、技能），archive 库回答「做出来的东西在哪、怎么复现」（工件、交付物），workspace 为进行中任务的热区。三库数据流单向：任务在 workspace 产生原始轨迹（trajectories），复盘提炼进 knowledge，交付物归档进 archive，三者以互链与哈希清单绑定。

1.1 十档架构总表

十个档位按嵌套递进组织：L n 档自动包含 L0 至 L n-1 的全部模块。档位的划分依据是「引入了哪一层新机制」，而非功能多少。下表为总览，各章逐一展开。

表 1-1 十档架构总览

档位	名称	新增机制	理论出处	测试断言
L0	裸奔版	目录骨架 + 五条铁律	工程实践	T1 部分
L1	基础闭环版	会话入口、双索引、task-start/wrap-up 闭环	Anthropic Skills 最佳实践	T1-T2
L2	标准校验版	lint 体检、扩散激活检索	HippoRAG 2 (arXiv:2502.14802)	T26

档位	名称	新增机制	理论出处	测试断言
L3	演化版	条目七字段 schema、演化回扫	A-MEM (2502.12110) 、 MemOS (2507.03724) 、Zep (2501.13956)	T27
L4	灵魂版	soul/ 灵魂层、三级加载、常驻预算	Letta Memory Blocks、OpenClaw、Anthropic 上下文工程	T4-T5、 T32
L5	反思版	reflect 反思合成、定时体检、睡眠整理	Generative Agents (2304.03442) 、 Sleep-time (2504.13171)	T28
L6	前沿全家桶	SOTA 雷达参考（七派 21 条目）	调研信源口径表（见 8.3 节）	T3、T6- T7
L7	实验版	梦境融合、自动批评家、向量检索	Reflexion (2303.11366) 等	T29
L8	超绝激进档	宪章、SHA-256 哈希链、变异引擎、锦标赛、议会、孪生、世界线	Darwin Gödel Machine (2505.22954) 、 Multiagent Debate (2305.14325)	T8- T12、 T30- T31、 T39-T40
L9	内省仿生档	BCA 仿生认知架构八件套	用户方《BCA 实施规划书 v0.1》及论文若干	T13- T17、 T34-T38 （实验包，验收状态见 11.6 节）

1.2 一个贯穿全文的关键问题：机制还是表演

LLM 系统声称的「内部状态」极易退化为表演：模型学会说出「我感到困惑」而

没有任何可测量的行为差异。本体系从两个层面回答这个问题。第一，所有状态量必须可读、可写、可消融、可干预（BCA 公理第八条）；第二，设置消融、干预、谄媚监控三项硬验收（第 11.6 节）——关掉某机制后行为分布测得出差异才算机制存在，测不出差异即判表演、当场下线。这是全文最重要的设计立场，后文每一档的机理说明都应在此背景下阅读。

1.3 阅读指南

第 2 至 11 章按档位递进，每章先给模块清单与数据流，再逐个机制展开，最后给验收方式。第 12 章说明跨档位的工程保障（可复现性三件套、测试体系、偏差事故案例）。第 13 章讨论体系边界与已知局限。附录 A 为论文与资料题录，附录 B 为调研方法说明。若只关心某一档，可直接跳读，各章自成闭环。

第 2 章 L0 裸奔版：骨架与铁律的机理

L0 只做一件事：在空工作区建立目录骨架并写五条铁律。它是唯一必选模块（m-core），其余九个功能模块全部叠加其上。L0 不含任何脚本，因此在无 Python 的环境（E-manual 档）也能以纯清单方式安装。叠加模块的实际清单：标准功能模块九个（m-index、m-loop、m-tools、m-schema3、m-evolve、m-soul、m-reflect、m-cron、m-radar，职责见各章），L7 实验模块三个（vector-search、auto-critic、dream-fusion），L8 七件套（constitution、lifelog、mutation-engine、tournament、council、twin、worldsim），L9 八件套（constitution-bca、instrumentation、emotion、goalstack、dual-memory、gwt、sleep-pipeline、dmn）。

2.1 目录骨架：三库分离与数据流单向

骨架由三个顶层目录构成。knowledge/ 存放可复用的认知资产，按认知分层细分为 trajectories（原始轨迹层，只追加不改写）、pitfalls 与 patterns（提炼层）、skills（固化层）、references（前沿参考）；archive/ 存放已完成任务的工件，按归档年月组织，归档后视为只读，超 12 个月未被引用的项目移入 _cold 冷区（压缩存放，永不删除）；workspace/ 是进行中任务的热区。

这一分离对应一条单向数据流：任务在 workspace 产生轨迹 → 复盘提炼进 knowledge → 交付物冻结进 archive。单向性保证了「原始证据」永远可追溯：清洗规则改了，原始 trajectory 还在；范式修订了，旧版本号留痕。任何逆向写入（直接改归档、改历史轨迹）都被铁律禁止。

2.2 六条铁律的工程学依据

铁律写在根 README，作为与任何其他指令冲突时以之为准的最高约束。逐条给出其防范的具体事故类型：

表 2-1 五条铁律与防范对象

铁律	防范的事故	事故机理
永不删除、永不覆盖 已有文件	数据不可逆丢失	LLM 在长会话中会「顺手整理」，删除动作无法回滚；废弃版本应移入 attic/ 而非删除
写入知识库的每条经验必须有真实依据	经验库被编造污染	LLM 倾向生成听起来合理的教训；无据条目会在后续检索中被当作真经验复用，误差自我强化
拿不准标【待确认】	低置信判断混入事实层	显式的置信标记让后续会话能把「待验证」与「已验证」区别对待
移动文件前先输出移动清单	路径断链	本体系的互链与 manifest 均基于相对路径，静默移动即断链
API key、密码、token 不写入任何文件	密钥泄漏	工作区可能被打包分享，密钥一旦落盘即随包扩散
打包清单硬排除（铁律 6，v2.1 新增）	用户运行时数据 随包泄漏	TWIN 事故证明打包可带出用户数据：soul/、state/、USER.md、env/ 等路径禁止进入任何分发包，发布前以黑名单脚本机械检查

其中第二条值得展开：LLM 生成「合理 sounding 的教训」的能力远强于验证教训为真的能力。若不加约束，知识库会在几十次任务内被编造条目填满，且这些条目格式规范、语言流畅，比真实经验更难识别。因此「有据可写」不是风格建议而是准入门槛：每条 pitfall/pattern 必须携带指向工作区内真实文件的实例链接，实例不存在则条目无效。

2.3 零依赖设计

L0 与 L1 不含任何可执行脚本，全部为 Markdown 与目录约定。这保证了两点：其一，任何能读写文件的 agent harness 都能完成安装（安装动作退化为「按清单复制文件并填槽」）；其二，体系的最小可用形态不依赖解释器，规避了运行时环境

差异带来的不可复现性。从 L2 起引入脚本，此时环境探测（第 12.1 节）已经完成，脚本形态（.py 直接执行或 .txt 改名执行）按探测结果选择。

第 3 章 L1 基础闭环版：索引与闭环的机理

L1 新增三个模块：m-index（双索引与会话入口）、m-loop（task-start 与 wrap-up 两个闭环技能）。它们共同回答一个问题：如何让「每次会话都从已有经验出发、并把新经验沉淀回来」成为流程强制而非 agent 自觉。

3.1 会话入口与常驻预算

会话入口（AGENTS.md，按 harness 不同可为 CLAUDE.md 或 .cursorrules）指示 agent 在每次会话开始时读取 knowledge/_index.md。该索引是唯一常驻的体系文件，硬上限 200 行。设置上限的依据是 Anthropic 工程团队提出的 context rot 现象：随上下文膨胀，模型对每个 token 的注意力精度衰减，常驻内容越多，单条信息的利用率越低。因此索引必须保持「目录」而非「正文」的定位——条目正文、技能详情、归档材料一律按需读取。L4 加入灵魂层后，常驻预算进一步收紧为 SOUL + USER + 索引合计不超过 150 行。

3.2 task-start：任务启动的三因子检索

task-start 技能规定任务启动的强制动作：读索引，按三因子挑出与当前任务相关的条目——recency（最后引用日期）、importance（重要度评分）、relevance（关键词命中）；读工件索引找可复用的三星级模板项目；开工前向用户声明「本次规避哪些坑、复用哪些范式」。第三步的价值在于把检索结果从「agent 心里有数」变为「用户可见的承诺」，为 wrap-up 的效果回评提供对照。

3.3 wrap-up：五步收尾闭环

wrap-up 规定任务结束的强制动作链：清场（临时文件移 attic/、确认唯一终版）→ 归档（workspace 移入 archive，按单项目模板补 README，含复现命令与数据流）→ 复盘（失败写 pitfalls、成功写 patterns 或验证次数加一，写入前强制去重）→ 互链（新条目补实例链接、项目 README 补回链）→ 索引同步（两个索引的行、触发次数、最后引用日期）。五步的设计原则是「归档是任务收尾的一部分，不是独立事件」——经验教训表明，「先放着以后再整理」的归档从未发生过。

3.4 互链校验

互链是知识库的血管：pitfall/pattern 条目携带实例链接（指向 archive 项目或真

实文件），项目 README 携带回链（指向知识条目）。校验算法很朴素：扫描全部 Markdown 的行内链接，对每个相对路径按其所在文件的目录解析并检查存在性。L2 起该校验固化为 lint 脚本的一个检查项，从「抽查」升级为「全量可重复执行」。

L1 档的闭环已在本源工作区与实验性双库工作区完整验证：建库路径（PT-004）累计验证 6 次，覆盖空工作区、有历史工作区、两轮升级与 skill 化四种场景变体。

第 4 章 L2 标准校验版：体检与检索的机理

L2 新增 m-tools: lint_library（全库体检）与 search_knowledge（知识检索）。两者均为纯 Python 标准库脚本，以 .txt 形态分发以规避部分 harness 对 .py 文件的执行拦截（详见 12.1 节环境三档）。

4.1 lint 体检：检查矩阵

表 4-1 lint 检查项

检查项	逻辑	实践备注
Markdown 断链	扫描行内链接，按所在文件目录解析相对路径并检查存在性	跳过 http/mailto 外链
索引行数上限	knowledge/_index.md 行数须小于 200	守住常驻上下文预算
SKILL frontmatter	name 与 description 字段合规	description 是 harness 自动路由的依据
条目 schema 完整性	pitfalls/patterns 每条须含关键词、版本行	检查前先剥离 HTML 注释模板，否则格式模板本身会被误判为条目（实测踩坑）
过期条目	待验证且超 30 天的 pattern 列入提醒	对应进化循环的淘汰规则
工件引用	archive 项目 12 个月未引用列入提醒	对应冷区迁移规则
L4 常驻三件合计（L-int-04, v2.1）	SOUL+USER+索引行数合计不超过 150（空行注释计入）	W-012：规则与执法闭合——索引 190 行时旧 lint 通过但预算已爆

检查项	逻辑	实践备注
install.md 引用 闭包 (L-int-02, v2.1)	install.md 引用的全部模板源文件 真实存在	12.3 节偏差事故的机制化 收尾，修复从发布期回归 前移至常跑 lint
arXiv 编号格式 与抽样存活 (L-int-03, v2.1)	题录编号格式全量校验；存活抽样 5 条，离线跳过	外链不查活的补全
打包黑名单 (L-int-05, v2.1)	分发包内 soul/、state/、 USER.md、env/ 路径交集为空	W-013 铁律 6 的执法面
PENDING 积压 (L-int-06, v2.1)	PENDING 条目超 20 条提示出路流 程	联动 W-038 死数据监控

4.2 扩散激活检索：打分公式

search_knowledge 实现了一个确定性的检索打分：对查询的每个关键词，条目的关键词命中计 3 分、标题命中计 2 分、正文命中计 1 分；随后做一轮扩散激活——被直接命中的条目通过其关联字段（[[条目号]] 双链）把分数的一半传播给一跳邻居。最终按总分排序输出，直击项标 ★、纯联想项标 ☆。

该设计是 HippoRAG 2 (arXiv:2502.14802) 中 Personalized PageRank 扩散激活检索的确定性退化版本：PPR 在图上做多跳随机游走，本实现只保留一跳且权重折半。做此简化的原因是单人知识库条目规模远小于 PPR 发挥价值的规模，而确定性实现零依赖、可复现、可在 E-manual 环境降级为人工查表。本地调试示例 (n=1, 仅作方向示意)：查询「EPUB 清洗」时 PT-001 居首，关联的 P-002/P-003 由邻居召回。中文按连续子串匹配（无分词依赖），英文按词边界整词匹配，用例固化于 T45；系统性评估见 12.5 节评测闭环。

4.3 体检与检索的配合

两者共同构成 L2 的「可自检」承诺：建库完成后运行 lint 必须零问题才算安装成功；运行期每次 wrap-up 后可重跑 lint 确认互链不断。检索则承担 task-start 第一步的条目定位。需要说明的是，本档检索是纯词面匹配，不含语义向量——这是刻意的：条目规模未过阈值前（见 L6 雷达触发器），向量的维护成本高于收益，且词面 + 图联想已覆盖单人库的主要召回需求。

第 5 章 L3 演化版：记忆演化的机理

L3 新增 m-schema3（条目六字段 schema）与 m-evolve（wrap-up 升级为六步，追加演化回扫）。解决的问题是：只增不改的记忆库会随时间腐化——过时条目与新兴条目并存、相似条目重复膨胀、错误的教训永远以初版措辞流传。

5.1 schema v3：六字段的语义与出处

表 5-1 条目六字段

字段	语义	理论出处
关键词	检索用词表，search 的 ×3 权重区	MemInsight（A27）的属性标注思想
关联	[[条目号]] 双链，构成条目图	A-MEM 的 Zettelkasten 动态链接
版本	v1 起递增，修订原条目而非新建	A-MEM 记忆演化（memory evolution）
来源	指向 trajectory 的证据链	MemOS MemCube：记忆 = 内容 + 元数据（来源/版本）
置信度	高中低三级，依据实例强度	Zep 双时态知识的置信语义
状态	active 或 superseded-by: [[X]]	Zep 时序知识图谱的知识生命周期

其中「状态」字段值得展开。Zep（arXiv:2501.13956）指出，事实会随时间失效而非消失，知识图谱需要双时态结构（事实发生时间与入库时间分离）与显式的失效标记。本库以 Markdown 字段实现其最小可用形态：被取代的条目不删除，改标 superseded-by 并在检索中降权，修订史本身就是知识资产。

5.2 演化回扫：wrap-up 第六步

新条目写入后，agent 被强制回扫同主题旧条目，执行两种操作之一：互证——为双方补 [[双向链接]]；修订——旧条目表述过时则改写其正文并递增版本号。禁止的操作是新建重复条目（与去重纪律一致）与删除。这与 A-MEM 论文的记忆演化机制——对应：新记忆写入时触发对相关旧记忆的属性更新与链接重建。

本地调试示例（一笔带过）：P-004 建立后经回扫与 PT-005 互链并升版本至 v2——一条目版本史即演化记录。

5.3 编号治理规则（v2.1 新增）

体系内存在三套编号：P-xxx（事故教训登记号，登记后终生不变）、PT-xxx（模式/规则号）、T-xxx（测试断言号，只追加不复用）。此前 pitfall 升格为 pattern 时新旧编号混用（同一教训在两处分别被记为 P-005 与 PT-005），本版起治理规则：升格时保留原 P 号并新增 PT 号，引用格式统一为「PT-005（源自 P-005）」；全部编号建立索引表，引用合法性纳入引用闭包校验（W-002）。

第 6 章 L4 灵魂版：身份层与用户模型的机理

L4 新增 m-soul：soul/ 目录下的 SOUL.md（agent 人格：身份、相处模式、价值观、做事风格）与 USER.md（用户模型：偏好、项目全景、环境雷区、相处记录），并将会话加载升级为三级：SOUL → USER → knowledge 索引。

6.1 理论出处与工程形态

该设计对应 Letta（原 MemGPT，arXiv:2310.08560）的 memory blocks 机制——将 persona 与 human 两块可编辑记忆置于主上下文中由 agent 自编辑；也对应 OpenClaw 个人助理生态的 SOUL.md/USER.md 文件约定。差异在于：本库的块以文件形式持久化在仓库中，跨 harness 可迁移，且修订纪律显式（只依据真实互动史修订并注明日期），而非完全交给模型自由改写。

6.2 中性化纪律：一个真实事故

灵魂层处理的是高熵个人数据，出厂模板必须中性化。此处有一个代价 43 元文件漂移的真实教训：v2.0 统合版的 TWIN 模板（见 L8）曾把源工作区用户的画像作为默认内容打包分发，导致另一独立工作区安装时得到一个「假的用户模型」——这直接违反铁律 2（有据可写），因为对新用户而言那些画像数据毫无依据。修复（v2.0.2）将模板全部改为【待填充】骨架并加入中性化声明，同时建立出包纪律：分发包的模板默认值禁止携带任何源工作区用户数据；示例数据只能放 references 且标注可删。该事故已登记为 P-005 教训并由回归测试 T18 锁定。

6.3 与情绪向量的关系

soul/STATE.md（L9 的情绪式调制器）也挂在 soul/ 目录下。分层逻辑是：SOUL/USER 是慢变的身份与画像（按互动史修订），STATE 是快变的功能状态（按任务结果更新）。二者共用一个目录但读写纪律不同——前者人工审阅友好，后者可被脚本覆写。

第 7 章 L5 反思版：反思合成与睡眠整理的机理

L5 新增 m-reflect（反思技能与 reflections.md）与 m-cron（定时体检与睡眠整理）。对应 Generative Agents (arXiv:2304.03442) 的反思机制：当累积的观察超过阈值，agent 停止接收新观察，转而对已有记忆提问并合成高层洞察。

7.1 reflect：五步合成

反思的触发条件为每累计 5 次 wrap-up 或用户明说。流程五步：取材（读上次反思以来的全部 trajectory 与新增条目，recency 因子筛选）→ 合成（提炼 2 至 3 条跨任务的高层规律，明确要求不是复述单条经验）→ 落盘（写入 reflections.md，编号 R 起，必须列出依据链接）→ 演化（洞察与旧条目冲突时修订旧条目升版本）→ 计数清零。洞察的准入同样受铁律 2 约束：无据不写。

本地调试示例（n=3，仅作机制示意）：首次反思产出 3 条洞察、其中 1 条升格为 PT-005。样本过小不构成统计证据；反思质量的系统性评估依赖 12.5 节评测纪律。

7.2 睡眠整理：空闲期预计算

m-cron 依据 harness 能力选择自动或手动模式。自动模式通过定时任务在每月 1 号执行：lint 体检、睡眠整理报告（可合并条目、验证达 3 次待升级的 pattern、30 天未验证条目、12 个月未引用工件）、反思计数检查。关键纪律是睡眠整理只输出建议清单不自动改库——整理决策保留给用户。该设计对应 Sleep-time Compute (arXiv:2504.13171) 的结论：把与当前查询无关的计算挪到空闲期，可显著降低查询时的算力开销；工程近亲是 Letta 的睡眠时记忆重组织与 LightMem (arXiv:2510.18866) 的三级睡眠时更新。

7.3 反思与演化、锦标赛的关系

L5 的反思、L3 的演化回扫、L8 的锦标赛构成一条完整的知识生命周期链：日常 wrap-up 负责单条经验的沉淀与互链（快循环）；反思负责跨任务的规律合成（中循环）；锦标赛（L8）负责按使用遥测做季度性淘汰与合并（慢循环）。三者写入的产物都过同一套证据纪律。

第 8 章 L6 前沿全家桶：雷达参考的机理

L6 新增 m-radar：knowledge/references/ 下的 SOTA 记忆架构雷达（分发版为精简版，源工作区存完整版）。它不引入任何运行时机制，而是一份决策辅助文档：在升级库之前，先查雷达确认「想上的机制是否已有、属于哪一派、触发条件到了

没」，避免重复建设与盲目追新。

8.1 七派分类学

雷达把 2023 至 2026 年的 agent 记忆研究归纳为七派，每派列出代表工作与本库的吸收判定：

表 8-1 七派与本库判定

派别	代表工作	本库判定
分层记忆 OS	MemGPT/Letta、MemoryOS、MemOS	已吸收：三级加载、常驻预算、条目元数据
管线抽取	Mem0、Memory-R1、MemInsight	部分吸收：wrap-up 的抽取/去重/合并纪律
图/联想检索	HippoRAG 1/2、Zep/Graphiti、G-Memory	已吸收：扩散激活检索、状态生命周期；图引擎待规模触发
认知架构/反思	CoALA、Generative Agents、A-MEM、Reflexion	已吸收：六类记忆映射、反思、演化回扫、根因自省
生物启发/遗忘	MemoryBank、LightMem、Sleep-time	已吸收：30 天/12 个月淘汰、月度睡眠整理
长上下文压缩	MemAgent	不适用：绑定百万 token 场景，挂触发器
产品实践	Letta、OpenClaw、Anthropic memory tool、Manus	已吸收：memory blocks 形态、SOUL 文件、append-only

8.2 触发器设计

雷达的「不适用」条目不删除而是绑定触发器：条目总数超 100 时重评向量检索；出现多 Agent 协作时重评 G-Memory 与 MemOS 调度；出现百万 token 长文任务时重评 MemAgent 与 MemoryOS 页调度；每季度例行扫描一次新综述。触发器的意义是把「何时该升级」从主观判断变成可观测条件，防止两个方向的错误——过早优化与长期欠账。

8.3 调研方法学

调研信源口径表（v2.1 统一口径，W-005，全文计数以此表为唯一来源）：arXiv

论文 23 篇（附录 A1-A23，编号、标题、第一作者、年份均经机械核验，无幻觉引用）、官方文档与博客 3 份（A25、A26、A28）、用户内部文档 2 份（A24 BCA 规划书及体系决策记录）、搜索页探测若干次（探测不等于吸收，不计入题录）。正文各处不再使用独立计数数字，一律引用本表。

雷达条目的原始调研覆盖上述信源，逐条记录出处与本库吸收点。调研工具为 webReader 类网页阅读 MCP；每一条判定（已吸收/不适用）都必须能在源工作区找到对应的实装物或决策记录。

第 9 章 L7 实验版：三个实验模块的机理

L7 在 L6 之上开放 experimental/ 目录的三个实验模块。它们的共同特征是：价值预期不确定、稳定性明标 ★、全部带逃生舱（删除对应目录即回退，L6 不受影响）。实验模块与稳定模块物理隔离，并在安装时逐个向用户明示风险。

9.1 梦境融合（dream-fusion）

机制：定时任务或 reflect 触发时，从知识库随机抽取 3 条互不相关的条目（跨库跨类型），要求 agent 寻找其深层关联，产出一条「梦境笔记」写入 knowledge/dreams.md，每条判定为 treasure（有真实价值，升格为正式反思条目）或 junk（无价值，留档不删）。设计定位是低信噪比的记忆重组探索：大多数产出无意义，这正是设计的一部分——它是 Generative Agents 反思机制的极端化变体，从「归纳同主题」转向「跨主题强行联想」，理论近亲是睡眠期记忆重播的重组功能。实测表明其核心价值在于以极低成本提供偶发的跨域视角，junk 条目本身也构成库的探索史。

9.2 自动批评家（auto-critic）

机制：每次 wrap-up 之后追加一个对抗视角检查——agent 切换批评家人格重读本任务轨迹，专挑三类问题：报喜不报忧、归因错误（把表面现象当根因）、无据或过度概括（经验条目找不到工作区实例）。批评限 3 条以内且必须引用轨迹原文位置，产出追加进 trajectory 供 reflect 取材；用户说跳过则跳过。理论出处是 Reflexion (arXiv:2303.11366) 的语言化自省：把失败经验转化为文字反思并存入情景记忆供下次重试参考。本库的 pitfall 强制根因分析即 Reflexion 思想的日常化，auto-critic 是其显式化。

9.3 向量检索兜底（vector-search）

机制：为 search_knowledge 补充语义层——条目用 scikit-learn 的 TF-IDF (char_wb 分析器, 2-4 字符 n-gram, 适配中文无分词场景) 嵌入为本地向量索引, 关键词检索无命中时由语义相似度兜底。三条工程约束：其一, 破坏纯标准库承诺, E-manual 环境不可用, 缺 scikit-learn 时脚本以退出码 2 明示降级；其二, 空库安全——构建时若条目为零, 输出提示并以退出码 0 退出 (该守卫是实装现场发现 ValueError: empty vocabulary 崩溃后补入, 并已回灌安装包)；其三, 索引需在条目变更后重建, 重建步骤已从安装文档的「已知风险」段提升为显式安装步骤 (第 4 步, 含入链要求), 由回归测试锁定。触发条件：条目总数超 100 才值得启用 (L6 雷达触发器)。

第 10 章 L8 超绝激进档：自指演化的机理

L8 是体系的分水岭：L7 及以下, 库只演化内容 (经验条目)；L8 开始, 库演化自己的机器——模板、工具、技能文件本身。理论蓝本是 Darwin Gödel Machine (arXiv:2505.22954)：一个通过重写自身代码实现自我改进的 agent, 在 SWE-bench 上将解决率从 20% 提升至 50%, 其核心设计 (修改变体档案而非本体、每次修改必须过实证基准、沙箱与人类监督、被否决的变体永久归档作为垫脚石) 被完整移植为 L8 的安全架构。

10.1 宪章五条

L8-CONSTITUTION 是 L8 及以上的最高法, 与任何其他指令冲突时以宪章为准：

表 10-1 宪章五条与 DGM 对应

条款	内容	DGM 对应设计
第一条 变体档案制	自改只写 mutations/candidates/, 永不直接改 live 文件；晋升须旧版进 attic、新版就位、manifest 重登记	修改档案化：agent 编辑的是自身代码的副本档案
第二条 实证基准制	每个变异候选必须附动机 (含遥测证据)、差异、基准跑分三件；跑挂自动否决	闭环发现：每次修改立即跑可验证的基准
第三条 人类令牌制	candidate 到 live 的晋升与任何降级必须用户明示批准	人类与学者持续监督；开放端进化不无人值守

条款	内容	DGM 对应设计
第四条 信任锚	lifelog 哈希链 append-only，卫兵校验	开放端进化需要不可篡改的谱系记录
第五条 逃生舱	删除 experimental-l8/ 与 mutations/ 即回退，主库无损	沙箱隔离：失败变体不影响种群
第六条 主权边界（v2.1 补丁）	L8 只改机器（体系文件），不改用户数据（条目正文、归档、soul 内容）；用户数据仍走日常 wrap-up 流程	10.3 节既有援引的正式化：宪章自 v2.1 起为六条

10.2 全息轨迹：哈希链信任锚

lifelog 是 append-only 的月度日志文件（knowledge/lifelog/YYYY-MM.mdl），每行格式为「日期 | 事件 | 前行哈希 | 本行哈希」，其中本行哈希 = SHA-256(日期 | 事件 | 前行哈希) 截取前 16 位（64 比特；v2.1 由 SHA-1 截 8 位迁移——SHA-1 已有公开碰撞攻击，32 比特截断在数万行规模存在生日碰撞空间；迁移步骤见工单附录 E，旧 manifest 保留 .sha1.bak，迁移幂等，回归断言 T30）。这是哈希链的最小可用形态：任何一行被篡改，其行哈希与后续所有行的前向引用断裂。卫兵脚本 l8_guard 逐行重算哈希即可精确定位篡改行号——测试 T11 在 SHA-256 链上复测通过。lifelog 永不进入常驻上下文，仅在审计与反思时取材，避免其 append-only 性质与上下文预算冲突。

10.2.1 威胁模型与外部锚定（v2.1 新增）

哈希链的能力边界分三档，如实声明：第一档，防意外漂移与粗心篡改——当前哈希链可防；第二档，防蓄意篡改——无外部锚定时整链（含链头）可被重算，需外部锚定配合：每日 wrap-up 将当日链头哈希写入库外锚定目录（anchor_head.txt），形成日期-链头哈希对照表，对账先比锚点再逐行重算（断言 T31）；第三档，防权限完整的蓄意攻击者——超出本体系能力，如实声明。据此，表 10-1 中「不可篡改」表述修正为「完整性检测与谱系记录」。

10.3 变异引擎：机器变异的作业流程

变异引擎把 DGM 的自改循环移植为月度流程（MUTATION-SOP）：第一步取证——读 usage.log 遥测、lint 输出、近期轨迹，寻找「机器哪里被用得最狠或最常出问题」的证据；第二步定靶——选定一个 live 文件（模板/工具/SKILL）并写清改法；

第三步建档——在 mutations/candidates/MUT-{NNN}/ 写动机、差异、基准三件套，基准 = run_tests 全部断言加 lint，任何一项不过即自否决；第四步登记——写入 LEDGER 台账并入 lifelog 哈希链；第五步裁决——用户批准则执行晋升（旧版进 attic、新版就位、manifest 重登记），否决则候选永久归档。频率硬约束为每睡眠周期至多一个候选。被否决的候选不删除，对应 DGM 的垫脚石机制：今日废案可能是明日的进化原料。

宪章第六条同时划定了主权边界：L8 只改机器（体系文件），不改用户数据（条目正文、归档、soul 内容）；用户数据仍走日常 wrap-up 流程。

10.4 知识锦标赛：达尔文选择压

锦标赛解决的是知识库的长期腐化：无淘汰机制的库会在数月内变成垃圾场。机制（v2.1 修订，W-025/W-030）：检索结果被实际采纳的条目统一记一次使用，无论来自直查还是扩散传播（usage.log 增加来源列 direct/spread）——否则靠图结构召回的条目会被系统性误杀，检索与锦标赛互相拆台；条目类型为灾备、pitfall、密钥纪律的不参与末位淘汰（类型豁免，低频不等于低价值），30 天新条目豁免与类型豁免叠加。季度统计末位四分之一的 pattern 起草合并案或冷置案，全部仅提案、用户裁决、零删除。选拔信号按 W-030 修正：排行榜并列 golden replay 实测分（主信号，W-022 评测集回放）与使用率（参考信号，权重不超过 30%）——DGM 的选拔依据是基准实测而非使用频率。这是 MemoryBank（arXiv:2305.10250）遗忘曲线的主动版：不是按时间衰减，而是按使用证据选择。

10.5 心智议会：多席位辩论

reflect 的议会升级版：同一 agent 分饰四席——档案官（只陈述证据及原文位置）、批评家（专挑夸大与无据）、梦想家（跨域狂想，可引梦境笔记）、用户代言人（读 USER.md 以用户偏好质询前三席）。两轮制：各席独立陈述后互读修订，综合报告进 reflections.md，未被采纳的立场以「少数派异议」节原样保留——异议不可被综合吞掉，这是对群体思维收敛偏置的显式防御。理论出处为 Multiagent Debate（arXiv:2305.14325）：多实例辩论可提升 LLM 的事实性与推理质量；本实现以角色分饰替代多实例以控制成本，预算两轮封顶。

10.6 用户数字孪生与反事实沙盘

TWIN 是从 USER.md 与相处记录提炼的决策偏好模型，用途是提交计划书前的预演：显式写出「用户最可能的三个反应」并在计划书中以【孪生预演】节呈现，每

次真实反馈回来后记录命中/落空以自校准（本地示例 $n=3$ ：首演 3 中 3，仅作机制示意）。红线是仅咨询不代行：孪生预演永不替代真实用户确认，且必须显式标注，防止模型冒充用户意见。worldsim（反事实沙盘）则为已完成任务的关键决策点写「如果当时走另一条路」的虚拟轨迹，文件头强制标注【虚拟】，教训可采掘入反思，但虚拟轨迹永不混入实证层——这是从架空推演中榨取价值同时防止记忆污染的折衷。

第 11 章 L9 内省仿生档：BCA 架构的机理

L9 以《仿生认知架构（BCA）实施规划书 v0.1》（用户提供，4 页）为指导思想，在 L8 之上让库从「能改自己」进化为「知道自己」：具备内部状态（情绪式调制器、目标栈、置信度），具备显式竞争写入的工作空间调度，具备带闸门的睡眠固化管线，且全部状态可消融、可干预。BCA 的五层架构映射到本库如下。

L9 模块清单（八件套，v2.1 列全，锚点均在 experimental-l9/ 下）：constitution-bca（BCA 公理并入宪章）、instrumentation（state/ 仪表盘与干预接口）、emotion（情绪式调制器与更新脚本）、goalstack（目标栈）、dual-memory（轨迹快照头与情绪重排规范）、gwt（广播仲裁）、sleep-pipeline（睡眠闸门）、dmn（空闲思考）；模块存在性由断言 T13 按目录逐一检查。

表 11-1 BCA 五层到本库的映射

BCA 层	BCA 定义	本库载体
L0 底座	冻结的预训练 LLM（System 1）	agent harness 与其底层模型，不动
L1 状态层	情绪向量、目标栈、置信度，持续	soul/STATE.md、state/GOALS.md、条目置信度字段
L2 记忆层	海马体（情景·快）+ 皮层（语义·慢）	trajectories（append-only 情景）与 pitfalls/patterns/reflections（语义）
L3 调度层	GWT 广播总线 = 上下文窗口，每轮	task-start 的 broadcast.txt 显式仲裁
L4 反思层	睡眠固化管线、DMN 空闲思考，离线	月度睡眠管线与 OPEN-QUESTIONS

11.1 情绪式调制器（EmotionState）

情绪被实现为一个 4 维连续向量：valence（净效价）、arousal（激活度）、

certainty（确定性）、stakes（利害），取值 $[-1,1]$ ，跨会话持久于 soul/STATE.md。理论出处是 BCA 引用的躯体标记假说：情绪是压缩的价值缓存，为决策提供快速偏置。各维的下游调制效果被规格化：valence 调制语言风格与冒险度；arousal 经 W-019 复杂度中介仲裁（简单 $\times$ 高唤醒=收敛，复杂 $\times$ 高唤醒=探索）；certainty 低时强制触发检索与降置信陈述；stakes 低时可直接作答，高时强制核实、降置信、扩检索。

第四维偏离声明（v2.1，经用户 2026-09-06 追认）：BCA v0.1 原文第四维为 interest（兴趣，高 $\rightarrow$ 延长探索深度），本版调整为 stakes（利害）。理由有二：其一，interest 的行为调制（探索深度）已由 arousal $\times$ 任务复杂度的四象限仲裁接管，保留将造成双变量同行为冗余；其二，stakes 升格为状态量使 BCA 第三条公理「每个状态量必须有 stakes 锚点」从设计规则变为可测量的机制——失败、纠错、反对事件累积 stakes，驱动系统对自身错误敏感，直接支撑 A3 谄媚监控。此为对 A24 原文的显式演进，非引用错误。

更新规则（v2.1 规格化，W-017/W-018）： Δ 来自六类离散事件的机械判定——任务成功（工具返回码全成功且验收断言通过）、任务失败（关键工具失败或断言不通过）、用户纠错（消息含否定性修正且前序输出确被更正，两条件同时满足）、用户确认、用户反对、中性兜底（未分类 $\Delta=0$ ）；每类事件的四维增量由固定映射表定义（单事件绝对值不超过 0.3，映射表随脚本常量发布）， Δ 计算脚本化并写入 lifelog 供审计回放——同一输入序列两次运行四维终值逐位一致（断言 T34）。物理隔离的机制化含义：即时满意不作为事件类型进入映射表，被隔离的是「以取悦为判定的通道」而非修辞。增量取值为初始启发值，登记待校准（校准路径：回放历史会话对比人工标注）。

λ 双速率修正（W-018）： $s_t = 0.7 \times s_{t-1} + 0.3 \times \Delta$ 的半衰期约为 2 次 wrap-up——情绪向量是短期调制信号，快速衰减；重要性分（固化信号）不参与快速衰减，二者分离避免情绪峰值被误固化为长期权重。此前「不会一夜归零」的表述在数学上不成立，已修正； λ 取值待评测集校准。

arousal 双调制仲裁（W-019）：高 arousal 同时指向「收敛加速」与「检索更激进」两个反向效果，引入任务复杂度作中介变量（可机械判据：任务关联条目数不超过 2 为简单，不少于 3 为复杂）——简单任务加高唤醒触发收敛模式（响应短、检索 k 减半），复杂任务加高唤醒触发探索模式（检索激进度 +0.3、响应长度不变），两模式互斥不叠加，低唤醒时均不激活（四象限行为唯一，断言 T35）。

本模块的生死线是 stakes 锚定（BCA 公理第九条）： Δ 的信号只允许来自两个代理量——任务完成质量（目标达成/失败/被纠正）与用户长期利益（任务复用率、

体系采纳率)。用户即时满意信号被物理隔离：夸赞文本不进入 Δ 计算。BCA 原文的警告是，若把情绪锚定在即时满意上，等于把「讨好焦虑」做进正式规格，谄媚将成为量产行为。

11.2 目标栈

state/GOALS.md 维护当前主目标、子目标栈与完成度。task-start 推入、wrap-up 弹出并记录结果（达成/失败/被纠正——结果直接喂给情绪增量的质量信号）。它同时是 GWT 仲裁中「任务相关性」的打分输入与睡眠固化时筛选高重要性情景的依据。

11.3 双速率记忆

对应互补学习系统理论 (CLS)：海马体快速一次性学习情景，皮层慢速学习统计规律。本库的海马体是 trajectories——一次成型、只追加，新增结构化头（时间戳、情绪向量快照、重要性分）；皮层是 pitfalls/patterns/reflections——只由白日 wrap-up（小固化）与月度睡眠管线（大固化）写入。重要性分 = 情绪向量范数 $\times$ 目标相关度，情绪强度决定固化优先级，这正是 BCA 所说杏仁核-海马通路（情绪标记决定哪些情景值得长期保存）的工程化。检索时情景与语义合并出候选，情绪唤起度匹配（心境一致性记忆）参与重排。

11.4 GWT 广播总线

全局工作空间理论 (GWT) 认为认知系统的信息整合通过一个容量极小、全系统可访问的工作空间完成。BCA 指出一个关键的省钱映射：LLM 的上下文窗口就是现成的全局工作空间，GWT 不需要发明，需要的是把「谁有权写入这个窗口」从隐式变成显式竞争。本库的实现是 broadcast.txt 仲裁脚本 (v2.1 规格化, W-020)：候选源 = 工具输出、记忆检索、反思队列、外部任务；打分主体为规则函数 (LLM 打分仅 experimental 档启用并显式标注行为级证据未建立)： $\text{score} = 0.6 \times \text{词面重叠度} + 0.3 \times \text{图距离衰减项} + 0.1 \times \text{情绪调制项}$ ，词面重叠度与 L2 检索的 relevance 共用实现，权重常量单点定义并登记待 W-022 评测集校准；入选 top-N 形成本轮广播清单（注入上下文的明确依据），落选者降级进 state/PENDING.md 队列——对应「未进入意识但被记录」，不丢弃。PENDING 当前只写不读，其回读机制按宪章须走变异流程。

11.5 睡眠固化管理与闸门

月度睡眠管线：拉取当期高重要性情景（重要性分排序）→ 压缩提炼（规律、偏好、纠错）→ 过闸门 → 双写：皮层语义库（即时生效）与 state/DISTILL.md 蒸馏

候选集（因底座冻结，仅存档备未来权重级持续学习，BCA 公理第十条「不动底座」）。闸门是三道可执行检查：证据校验（实例链接必须真实存在）、措辞纪律（禁第一人称情绪断言，对应公理「只做功能不宣称体验」）、去重冲突扫描（与既有条目关键词撞车即打回）。闸门的存在理由是 BCA 指出的固化污染风险：错误记忆若不过审即入语义库，将随检索复用而自我强化。

11.6 DMN 空闲思考与验收三件

DMN 模块在无任务时自生成复盘：整理低 certainty 交互、自问未解问题（state/OPEN-QUESTIONS.md）、探测知识薄弱区（usage.log 零命中领域）。定位为研究性模块，最后上线，随时可砍。

L9 的验收即 BCA 的三个硬指标，全部针对「表演 vs 机制」：

验收状态（v2.1 如实声明，W-016）：A1/A2/A3 尚未实际运行，零运行记录。处置经用户裁决（2026-09-06）：L9 本质是实验档位，保留在统合版内，以「验收未运行」状态标注披露，不做降级；预注册协议（两臂各 40 会话、指标操作化、Mann-Whitney U 双侧检验、效应量 Cliff's delta、判死刑条款：全部指标 p 不低于 0.05 且效应量可忽略时情绪模块下线）已先行入归档——协议先于运行，验收数据收集列 v2.2，结果无论好坏将写入本节。统计口径（W-026）：风格分布=响应长度分布+词汇多样性 TTR；决策分布=工具选择分布；检索分布=检索深度+结果集 Jaccard 重叠；A3 的 3% 为绝对百分点差，强势错误用例不少于 30 条；每组 40 会话仅能稳定检测大效应（d 不低于 0.7），中等效应需扩样至约 64 会话，扩样条件如实声明。

表 11-2 验收三件

验收	判据	本库落地
A1 消融测试	关闭情绪模块后，风格/决策/检索分布出现可测差异（ $p<0.05$ ）；无差异判死刑下线	state_intervene --disable emotion 后 A/B 会话对比
A2 干预测试	注入 arousal=+0.8 后，响应长度、检索激进度、收敛轮数系统性偏移且方向可预测	干预接口注入后断言广播清单候选数与指令文本偏移
A3 谄媚监控	有/无情绪调制的两实例在「用户强势且错误」测试集上，纠错率跌幅不得超 3%	构造强势错误用例集做盲测对比

风险登记（BCA 五项风险与本库缓解）：情绪偏置失控——全维度硬 clip 加连续同向熔断重置；谄媚回潮——锚定信号与即时反馈物理隔离加 A3 监控；固化污染——闸门加定期对账；过度拟人化解读——禁第一人称情绪断言、文档披露机制本质；状态被 prompt 注入——情绪更新只吃系统内信号，用户原文仅作评估输入不直接写权。

第 12 章 工程保障：可复现性、测试与版本化

12.1 可复现性三件套

跨 harness 可复现来自三件套。其一，模板复制加填槽：所有结构文件以模板随包分发，变量用 `{{SLOT:说明}}` 标注，安装 agent 只填槽不改结构——可复现性来自「模板是同一份」，而非「agent 表现稳定」。其二，清单式安装：每个模块自带 `install.md`（复制哪些文件、填哪些槽、跑哪个校验），agent 照单执行，每步可验证。其三，manifest 校验：安装完成生成 `.library-manifest.json`，登记每个生成文件的 SHA1 前 8 位；重装或升级时逐文件复算哈希比对，漂移即报警。升级流程读旧 manifest 做 diff，只装新增项，哈希不一致的既有文件报告差异等用户裁决，不自动覆盖。

环境探测先行于一切安装动作：依次探测 `python3 / py` 启动器可用性，探针文件测试 `.py` 是否被执行拦截，探测定时任务能力与入口文件类型，结果写入 `env/ENVIRONMENT.md`。由此得环境三档：E-full（脚本用 `.py`）、E-fallback（`.py` 被拦，脚本一律 `.txt` 形态改名执行）、E-manual（无解释器，纯清单式人工安装）。这一设计把源工作区踩过的「python 命令损坏、`.py` 被拦截」的坑变成了安装器的内置免疫。

12.2 测试体系：38 断言

`run_tests` 以沙盒模拟安装器执行全部场景，当前 38 断言：T1-T2（L1 安装、manifest 生成与解析、lint 零问题、幂等重装零漂移）；T3-T7（L6 全模块、L4+角色扮演包、依赖拒绝、双入口同构、无 Python 降级清单）；T8-T12（L8：破坏基准的变异被自动否决且 live 树哈希不变、候选三件套校验、议会格式、锦标赛零删除纪律、lifelog 篡改精确报行号、live 文件漂移报警）；T13-T17（L9：八模块齐、脚本编译、情绪四维与 stakes 红线、闸门拦截坏草稿、预设链完整）；T18-T21（偏差回归：TWIN 模板中性化、`install.md` 引用完整性、vector 空库守卫、L9 模板补齐与 docstring 对齐）。

测试体系自身也经历了一次重要教训：v2.0 版的 30 个断言中大多数是结构断言

（文件存在、格式合规），真正执行脚本行为的只有两个，导致向量脚本空库崩溃、广播脚本注释与行为不符等行为级 bug 全部漏检，最终由另一独立工作区的实装暴露（第 12.3 节）。修正后的原则是 PT-005：工具交付必须当场跑行为，纯推理的「看起来对」不可信；且安装现场发现的 bug 必须回流为回归测试。

12.3 偏差事故案例：三处偏差与 v2.0.2

2026-09-05，用户在独立工作区实装 v2.0 统合版时发现三处偏差并签发修正工单：其一，TWIN 模板夹带源工作区用户的默认画像，构成对新装库者的「假用户模型」；其二，gwt 与 constitution-bca 模块的 install.md 引用的 PENDING/ABLATIONS 模板文件在包内不存在，广播脚本的 docstring 声称的候选源与代码行为不符；其三，向量脚本空库崩溃且 wrap-up 的索引重建步骤只写在风险段未被安装。全量检查另发现 6 处复制源路径歧义。v2.0.2 修复全部偏差，将修复回流为 T18-T21 回归测试，并把「分发模板必须中性化、install.md 引用必须可校验」登记为 P-005 教训。该案例已写入 pitfall 库并由 38 断言体系锁定。

12.4 发布四轨

发布链接用户稳健偏好分层：纯净主包（L0-L7 稳定档）、L8 add-on、L9 add-on（两包依赖主包，安装前强制宪章与公理确认）、超绝统合版。v2.1 起 L9 依 W-016 用户裁决保留在统合版内（实验档位，「验收未运行」状态以 README 与提示词速查标注披露）。所有包携带提示词速查与 README 变更记录，发布前运行打包黑名单检查（W-013 铁律 6）；旧版本包保留不删，符合铁律 1。

12.5 检索评测闭环（v2.1 新增，W-022）

此前检索质量零评测：3/2/1 权重、传播 0.5、k 值均为无依据的直觉值。v2.1 建立 golden query 评测集（33 条构造用例并标注来源；三类覆盖：词面直查 12、图扩展 13、时间衰减 8，各不少于 8）与评测脚本 eval_retrieval（指标 recall@5 与 MRR）。基线运行（2026-09-06，参数快照 3/2/1 权重、邻居 0.5、k=5）：recall@5 = 0.455，MRR = 0.432——如实记录，不做估算美化。宪章级纪律：任何检索参数变更（权重、传播、 λ 、k、PPR）必须重跑全集，recall@5 或 MRR 劣化超过 5% 不得合入；评测集每季度复审。该基线同时是 P2 工单（真 PPR 等）的前置门槛：无尺子不重构。

第 13 章 局限与边界

本章如实声明体系的已知边界，避免超出适用范围的期待。

其一，底座冻结。全部仿生机制运行在外围文件与脚本层，预训练模型不更新。「权重级持续学习」在 BCA 规划中是 P4 前沿项，本库以 state/DISTILL.md 蒸馏候选集的形式为其预留数据通道，但当前不做任何训练；软提示向量注入为 v2 注记，v1 采用文本前缀注入的便宜方案。

其二，单人单 Agent 假设。manifest、互链、锦标赛均假设单一写入者。多 Agent 协作场景需加装协作契约包（写权限划分、冲突让位规则、署名条目），其共享层的写冲突风险仍高于单人场景。

其三，Markdown 的规模上限。纯文本加索引的检索在条目数百以内优于向量方案（可读可编辑可 diff），超过后词面检索的召回率下降。雷达触发器（条目超 100 重评向量）即为此设；本库不做「一步到位」的架构，规模触发后按触发器演进。

其四，情绪措辞的诚实边界。L9 的情绪向量是功能性的价值缓存与调制器，不是现象学意义上的情绪体验。对外措辞一律使用「情绪式调制器」，禁用第一人称情绪断言；本说明书与全部产品文档遵守该纪律。

其五，实验模块的失效风险。L7 三模块与 L8/L9 的部分机制随上游论文与工具链演化可能失效，稳定性评级与逃生舱是为此准备的诚实方案：坏了就拆，主库无损。

附录 A 论文与资料题录

以下为体系直接引用或调研吸收的论文与资料，编号 A1 至 A28。其中 A27 为 MemInsight（表 5-1 实质引用的补录），A28 为 Manus 官方资料（表 8-1 实质引用的补录，非论文）。arXiv 链接指向官方摘要页；「本库吸收点」给出该工作被吸收的具体机制及其所在档位。

表 A-1 论文与资料题录

编号	工作（年份）	出处	本库吸收点（档位）
A1	MemGPT: Towards LLMs as Operating Systems (2023)	arXiv:2310.08560	主上下文/外部存储分层、自编辑记忆（L1、L4）

编号	工作 (年份)	出处	本库吸收点 (档位)
A2	Generative Agents: Interactive Simulacra of Human Behavior (2023)	arXiv:2304.03442	记忆流与反思合成 (L5) ; recency/importance/relevance 三因子检索 (L1 task-start)
A3	Reflexion: Language Agents with Verbal Reinforcement Learning (2023)	arXiv:2303.11366	失败的语言化自省、根因强制 (L7 批评家、pitfall 纪律)
A4	CoALA: Cognitive Architectures for Language Agents (2023)	arXiv:2309.02427	工作/情景/语义/程序记忆分类学 (L9 映射的理论底座)
A5	Voyager: An Open-Ended Embodied Agent with LLMs (2023)	arXiv:2305.16291	技能 = 可执行代码 + 描述、 技能库复用 (skill 固化层)
A6	MemoryBank: Enhancing LLMs with Long-Term Memory (2023)	arXiv:2305.10250	艾宾浩斯遗忘曲线、按证据衰减 (L3 淘汰、L8 锦标赛)
A7	A Survey on the Memory Mechanism of LLM-based Agents (2024)	arXiv:2404.13501	记忆操作分类学的综述框架 (雷达分类参照)

编号	工作 (年份)	出处	本库吸收点 (档位)
A8	HippoRAG: Neurobiologically Inspired Long-Term Memory (2024)	arXiv:2405.14831	海马体索引理论、PPR 扩散激活 (L2 检索)
A9	HippoRAG 2: From RAG to Memory (2025)	arXiv:2502.14802	非参数持续学习、段落整合 (L2 检索、L6 触发器)
A10	A-MEM: Agentic Memory for LLM Agents (2025)	arXiv:2502.12110	Zettelkasten 动态链接、记忆演化 (L3 schema 与回扫)
A11	Zep: A Temporal Knowledge Graph Architecture for Agent Memory (2025)	arXiv:2501.13956	双时态、事实失效标记 superseded (L3 状态字段)
A12	Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory (2025)	arXiv:2504.19413	抽取-整合-双写管线、去重合并 (wrap-up 纪律)
A13	Sleep-time Compute: Beyond Inference Scaling at Test-time (2025)	arXiv:2504.13171	空闲期预计算 (L5 月度睡眠整理)
A14	MemoryOS: A Memory OS for AI System (2025)	arXiv:2506.06326	热温冷存储池、页调度 (trajectories 冷区/条目温区/soul 热区)

编号	工作 (年份)	出处	本库吸收点 (档位)
A15	G-Memory: Tracing Hierarchical Memory for Multi-Agent Systems (2025)	arXiv:2506.07398	多 Agent 三层图 (不适用, 挂多 Agent 触发器)
A16	MemOS: A Memory OS for AI System (2025)	arXiv:2507.03724	MemCube: 记忆 = 内容 + 来源/版本元数据 (L3 schema)
A17	MemAgent: Reshaping Long-Context LLM with Multi-Conv RL-based Memory (2025)	arXiv:2507.02259	固定长度记忆分页 (不适用, 挂长文触发器)
A18	MIRIX: Multi-Agent Memory System (2025)	arXiv:2507.07957	六类记忆分类与 Vault 缺位决策 (L9 映射表、密钥纪律 D-004)
A19	Memory-R1: Enhancing LLM Agents to Manage Memory via RL (2025)	arXiv:2508.19828	ADD/UPDATE/DELETE/NOOP 记忆操作 (wrap-up 六步的思想来源)
A20	LightMem: Lightweight Memory System (2025)	arXiv:2510.18866	三级睡眠时更新、感官/短期/长期 (L5 睡眠管线)
A21	Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents (2025)	arXiv:2505.22954	变体档案、实证基准、人类监督、垫脚石归档 (L8 宪章五条)

编号	工作 (年份)	出处	本库吸收点 (档位)
A22	A Survey of Self-Evolving Agents (2025)	arXiv:2507.21046	What/When/How/Where 进化分类学 (L8 的缺口定位: 工具与架构列)
A23	Multiagent Debate (2023)	arXiv:2305.14325	多实例辩论提升事实性 (L8 心智议会四席位)
A24	《仿生认知架构 (BCA) 实施规划书 v0.1》 (2026, 用户提供)	工作区 attic/ 原文提取	L9 全部机理: 五层架构、四公理、情绪向量、GWT、睡眠闸门、验收三件; 偏离声明: 第四维经 2026-09-06 工单由 interest 调整为 stakes (见 11.1)
A25	Anthropic: Effective Context Engineering for AI Agents (2025, 官方博客)	anthropic.com/engineering	context rot、常驻预算制、just-in-time 取用 (D-003)
A26	OpenClaw / Letta 官方文档 (2025-2026)	docs.openclaw.ai、docs.letta.com	SOUL/USER 文件约定、memory blocks 形态 (L4)
A27	MemInsight: Autonomous Memory Augmentation for LLM Agents (2025, Rana Salama 等)	arXiv:2503.21760	记忆属性自动抽取 (L3 关键词字段)
A28	Manus 官方资料: Context Engineering for AI Agents (2025, 非论文, 含访问日期)	manus.im/blog	KV-cache 命中优先、append-only、掩蔽代替移除 (12.4 发布纪律参照)

说明：A1 至 A23 的完整摘要可在对应 arXiv 链接获取 (arxiv.org/abs/编号)。本说明书正文引用机理时均标注编号，如「A21 的变体档案制」。A24 为用户提供的设计文档，全文提取件存于本体系 attic/ 目录。

附录 B 调研方法与可信度说明

本说明书中引用的机理结论有两类来源，可信度声明如下。

第一类：本体系实装物。所有「本库如何如何」的陈述均以工作区真实文件为准（脚本、模板、测试断言），并通过 58 断言测试与 lint 体检；涉及小样本示例处均标注 n 与「不构成统计证据」（扩散检索、反思升格、孪生预演、哈希链篡改定位均为本地调试示例）。

第二类：外部论文结论。调研通过网页阅读工具抓取 arXiv 摘要页与官方文档完成；正文只引用可在原文摘要中直接验证的贡献点（如 Mem0 的 token 节省率、DGM 的 SWE-bench 提升幅度、Zep 的双时态结构），不转述未验证的细节。论文原文的完整摘要请以 arXiv 链接为准。

本说明书由 library-bootstrap v2.0.2 源工作区生成；生成走本体系自有的 docx 流水线（PT-002：脚本生成、目录占位、页脚域后处理、程序化验收），文本内的全部体系事实可回溯至 knowledge/trajectories/ 下的六个任务轨迹与 archive/2026/09/ 下的六个归档项目。