

针对《异世界迷宫最深部为目标》这类"高密度心理刻画+多层反转+千年时间线"的群像作品，语料清洗的核心思路是：**以"分层清洗+结构化提取"为总原则，前期尽量保留原文的语言风格与心理独白，通过标签化、降噪、维度拆解，把线性叙事转化为可供 LLM 稳定检索的角色卡与世界观知识库。**这部作品的精髓恰恰藏在涡波的"演技假面"、玛利亚的病娇独白、诺斯菲的千年执念这些细腻的心理描写里，粗暴清洗会把这些灵魂细节一起抹掉。

一、原文来源与预处理

首要问题是解决"清洗什么"。《迷宫深部》有 web 版（成为小说家吧，2012–2021，已完结）与文库版（OVERLAP 文库，16 卷）两套语料，两者在伪名、剧情细节上存在差异——web 版前几章涡波化名"基督·欧亚"，文库版则改为"齐格弗里德·维吉托"，这是清洗前必须确认的底本。

****版权与用途边界：****建议仅做本地化、个人使用的知识库；如果做公开角色卡（如 SillyTavern 社区分发），不要把整段原文贴进卡片或世界书，只保留摘要、标签与少量代表性台词，正文自行改写。原作是 OVERLAP 出版的正式商业作品，不是纯 web 免费素材。

预处理动作清单：

- 切分卷/章：**按卷、章、场景三级切分，章内再按"场景切换"（空行、章节小标题、地点变动）切为段落块，每块 300–1500 字为宜，这是后续向量化与 LLM 抽取的最小单元。
 - 去噪：**剔除作者吐槽、更新公告、感想页、感谢语；剔除重复的技能/状态栏长模板（本作系统面板反复出现，保留首次完整版，后续用 [面板略] 占位即可）；剔除重复的迷宫地图描述。
 - 统一译名：**建立别名表——相川涡波 / アイカワ・カナミ / カナミ / 基督·欧亚(キリスト・ユーラシア) / 齐格弗里德·维吉托 均指向同一角色，但**不同伪名必须作为独立条目保留，并标注使用的时间线**（千年前后、web/文库差异），这是本作剧情反转的关键锚点。
 - 保留原味：**不要在中途改写措辞。涡波的内心独白（"我一定会帮你的，如果是为了这个，我会——！"）就是角色卡的灵魂语料，直接保留原文摘录。
-

二、人物维度提取：做"角色卡"

对每个主要人物，按固定维度从清洗后的段落块中抽取信息。本作的核心人物建议至少覆盖：涡波、拉丝缇娅拉·缇娅（迪亚布罗）、玛利亚、斯诺、诺斯菲、相川阳泷——他们彼此间的千年羁绊构成了全书骨架。

信息类型与保留策略：

信息类型	保留策略	去噪规则	落库字段
外貌描写	保留全部首次完整描写 + 关键变化	删除重复场景化描写	appearance
动作/战斗风格	保留招式描述、战斗行为习惯	删除流水账式打斗过程	behavior
语言风格/口头禅	保留原句，标注语境	删除旁人复述	speech_pattern, quotes
心理独白	全部保留 ，这是本作精髓	不去噪	inner_monologue
人际关系/羁绊	保留对话 + 心理互动片段	删除纯路人对话	relationships
剧情锚点/高光	保留关键转折原句	删除过渡描写	plot_hooks
隐瞒身份/双重人格	分层保留，标注"已知/未知"	不可合并	secret_layers

****对话标注法：****清洗时用简单标签给原文打标，方便后续 LLM 二次提取。例如：

- 1 | [涡波·对缇娅]「我绝对要救你。只要能救你，我会——!!」
- 2 | [玛利亚·内心独白]（这一段保留原文，标注其病娇心理层级）
- 3 | [诺斯菲·千年记忆·闪回]（千年前涡波与圣人缇娅拉制定迷宫计划的场景）

正则清洗示例（可直接套用）：

```
1 import re
2 text = re.sub(r'(作者的话|あとがき|※.*?※)', '', text) # 去作者话
3 text = re.sub(r'={3,}|-{3,}', '\n—场景切换—\n', text) # 分隔符
4 text = re.sub(r'(第.{1,3}卷|第.{1,3}话|第.{1,3}章)', r'\n\1\n', text)
5 text = re.sub(r'\n{3,}', '\n\n', text) # 压缩
6 # 对话行标注（日文引号「」与中文""都要兼容）
7 text = re.sub(r'^「(.*)」$', r'[对白]\1', text, flags=re.M)
```

一个可直接套用的角色卡模板（以涡波为例，精简版）：

- 1 | name: 相川涡波（アイカワ・カナミ）

2 | aliases: [基督·欧亚 (web版前章), 齐格弗里德·维吉托 (文库版), 次元之理的盗窃者]
3 | age: 17 (外表) / 千年以上 (真实)
4 | role: 主角 / 千年前莱文教始祖 / 第零层守护者
5 | appearance: |
6 | (原句摘录) 高二学生身形, 银灰色发.....
7 | 文库插画设定: 鹤饲沙树绘制的剑士装束.....
8 | personality:
9 | surface: 温柔善良、寡断软弱、以假面示人 (原文: '外在的善良温柔掩盖了内心的空洞')
10 | core: 空壳、重度依存症患者、妹控、将演技化为真实的信条
11 | growth: 从初期以妹妹为唯一中心 → 圣诞祭事件 → 觉醒为迷宫始祖身份
12 | inner_monologue:
13 | - "我一定会帮你的。如果是为了这个, 我会——!"
14 | - (保留 3-5 段最具代表性的独白原句, 标注章节)
15 | speech_pattern:
16 | - 常用短句自问自答, 语气克制但暗藏决意
17 | - 面对玛利亚时回避、缄默
18 | - 千年始祖身份觉醒后, 语调转冷、直白
19 | abilities:
20 | - 次元属性魔法 (魔力特化, 素质 7.00 → 6.21)
21 | - 冰结魔法、剑术 (原本属于妹妹阳泷)
22 | - 并列思考 (后期获得)
23 | relationships:
24 | - 阳泷 (妹妹): 一切行动的原点, 病态依存
25 | - 拉丝缇娅拉: 救赎与被救赎, 最终婚约对象
26 | - 玛利亚: 镜像依存, 同化火之理的关键
27 | - 诺斯菲: 名义上的女儿/妻子, 象征其无法获得真爱的执念
28 | secret_layers:
29 | - layer_1 (前期读者视角): 普通高中生穿越者
30 | - layer_2 (中期揭示): 千年前迷宫创造者、莱文教始祖
31 | - layer_3 (最终真相): 次元之理的盗窃者, 第零层守护者

三、世界观维度提取：构建知识库

本作的世界观密度极高，建议按"实体—规则—阵营—地理—时间线"五大模块抽取，每一模块单独建立条目，而不是堆成一大段设定。

世界观抽取维度表：

维度	抽取内容	本作对应示例
核心设定	迷宫本质、可许愿的深层、百层结构	千年前诞生于开拓大陆的巨大遗迹，可实现任何愿望
魔法/力量体系	属性分类、咏唱机制	火/水/土/木/风 + 稀有属性（光/暗/次元/星/血），咏唱分普通与代价咏唱
专属概念	独有术语的精确定义	理的盗窃者、魔石、魔石线、莱文教、探索者、圣人、使徒、魔

维度	抽取内容	本作对应示例
		石人类
阵营/势力	五国、公会、宗教	迷宫联合国五国（弗茨亚茨、瓦尔德、劳拉维亚、艾尔多拉琉、古尔亚德）、公会"史诗探索者"
地理	大陆、城市、层位	拜伦西斯大陆、开拓大陆、大圣堂、各层守护者镇守点
时间线	千年前后双线	千年前的境界战争、圣人媞娅拉、始祖涡波 vs 现代的迷宫攻略
规则机制	战斗/系统规则	素质值、技能面板、击败理的盗窃者的两种方式（战斗消灭或帮其实现留恋）

世界书条目模板：

```
1 | entry_name: 理的盗窃者
2 | keywords: [理的盗窃者, 盗取理, 守护者]
3 | definition: |
4 |     镇守迷宫十位数阶层的守护者, 实力异常强大。每个理的盗窃者
5 |     都从世界上盗取了某个特定的"理"。击败方式有两种：战斗消灭,
6 |     或帮助其实现留恋。
7 | source_chapters: [第X卷第X章]
8 | related_entries: [诺斯菲（光之理）, 阳泷（水之理）, 涡波（次元之理）]
```


四、本作的特殊处理要点

- 普通"爽文式清洗"（只留打斗和结论）会把这部作品洗成废纸，必须做以下特殊处理：
- **1. 时间线循环必须分层。**涡波既是"千年前的迷宫创造者"，又是"当下的攻略者"，还与妹妹阳泷、诺斯菲存在跨千年身份重叠。清洗时给所有相关段落打上 timeline: 千年前 / 千年后 / 千年前后交错 标签，抽取时按时间线分别入库，再在角色卡 secret_layers 字段中关联——切不可在一张卡里把三层真相混为一谈。
 - **2. 心理独白优先级最高。**本作的精髓是"高强度反转叙事 + 人物心理刻画"。玛利亚从奴隶到圣母玛利亚隐喻、斯诺的"害怕变得认真"、诺斯菲的千年求爱而不得，这些全部依赖心理独白承载。清洗规则上，独白段落即便再长也不要压缩，只需标注所属角色与情绪层级。
 - **3. 反转伏笔要单独抽取。**所有"读者当时以为是 A，后期揭示是 B"的段落，用 [伏笔: 角色X] 标注，抽取时归入该角色的 plot_hooks。例如涡波前期的"游戏系统恩惠，理由不明"，后期揭示为千年前的自我布局。

****4. web 版与文库版差异处理。********伪名、部分剧情细节不同。如果做完整知识库，两版并行清洗，用 edition: web / 文库 标注；如果只做一版，优先文库版（更完整、更精修），但要标注 web 独有设定以供补充。

****5. 群像关系网。********本作人物关系是"千年羁绊网"，不是简单的好友/敌人二元关系。建议用关系图而非线性列表存储：涡波 -妹妹→ 阳泷 -千年镜像→ 诺斯菲 -名义婚姻→ 涡波，这种循环结构用图数据库（如 Neo4j）或嵌套 YAML 表达最清晰。

五、清洗流程总览



****质检标准很直接：********随机抽 3 段原文，看清洗后的语料能否完整还原该场景的人物心理与剧情功能；随机挑 1 个角色，看角色卡能否准确回答"这个角色在千年前后分别是谁、对主角意味着什么"。能，清洗就合格；不能，回头补维度。

这套流程产出的角色卡可以直接接入 SillyTavern 等角色扮演前端（用 {{char}} 宏、mes_example 示例对话锁住角色语调），世界观条目可以喂给本地知识库或 RAG 应用做迷宫百科问答。关键是：**清洗不是压缩，而是重构——把叙事流变成结构化知识，同时把涡波那句"我绝对要救你"的灵魂原句原封不动地留在卡里。**

注:本文部分内容由AI生成,无法确保真实准确,仅供参考